MALT SS 论文 v7.5 审稿意见综合总结与改进计划

整理日期：2026 年 11 月 4 日。对象为当前 18 页正文及 30 页补充材料。

两份审稿意见均建议大修，并认可唾液腺 MALT 淋巴瘤与干燥综合征分类问题的研究价值。共同判断是：目前已经观察到回顾性图像分类信号，但尚未建立可信的患者级独立验证，也未证明临床诊断效用。下一步应首先核实病例、标签和评估对象，其次修复评估设计，最后完善模型论证与稿件呈现。

本计划保留现有模型性能表的最佳值加粗、次佳值下划线，也保留正文突出内部验证选定 checkpoint 的写法。重复训练细节继续放在补充材料。这里提出的是修订计划，未改动 v7.5 正文、原始图像、预测结果或模型。

一 两份意见的共同结论与侧重点

来源 D 为豆包审稿意见，来源 C 为 Codex 的审阅内容会话。下文的“核对判断”基于本地 v7.5 正文、补充材料及现有分析档案，区别于两位模型审稿人的原始判断。

问题	两份意见的关系	核对判断与优先级
患者独立性	D、C 均列为核心问题	患者链接尚未核实，风险成立；尚不能断言已发生跨分区患者泄漏。P0
参考诊断和病例谱	C 专门详述，D 纳入元数据缺项	需补诊断依据、部位、标本类型及复核流程。P0
外部染色与来源	D、C 一致	档案标签不能替代真实染色，57 张事后子集也不是已确认的纯 H&E 队列。P0
外部筛选过程	C 明确指出，D 概括提出	227→223→168 的流程缺少可复核的逐项原因。P0
选模与评估复用	D、C 一致	49 张内部验证参与选模；历史外部数据也被后续开发使用。需要评估设计修复。P1
架构增益和基线	D、C 一致	不能据描述性排名推断架构优越；已有部分对照，应先复用并核对。P1
病理医生比较	D、C 一致，C 另指出排名暗示	汇总计数不足以支持正式配对比较或 AI 辅助获益。P1
区域解释与质量控制	D 强调病理注释，C 另指出 Case 10	像素与坐标核查已有；真实组织含量和病理意义仍未解决。P1
类别不平衡和概率解释	D、C 一致	应突出特异度分母、NPV 和对照基准；不能将分数直接解释为患病概率。P1/P2
信息、附件和图文	D 偏术语、图注和格式；C 偏材料可审查性	部分提示已存在，不必重复堆叠；临床缺项与附件交付仍需落实。P1/P2

优先级定义：P0 为决定数据能否支撑结论的前置事项；P1 为有效评估和正式报告所需事项；P2 为依论文主张决定的增强工作。

二 应当采纳的实质性意见

1 先建立患者和参考诊断对应关系

内部 193 张、外部 168 张均是切片数，不能直接作为独立患者数。医院侧需要提供匿名患者、病例、标本、蜡块和切片之间的对应关系，连同诊断依据、唾液腺部位、取材方式、采集时期和复核记录。应检查同一患者、同一标本或连续切片是否跨分区，也要核查内部与外部来源是否存在病例重叠。对应原稿 C02、C06。

如果发现患者交叉，相关切片级评估需要按患者重新组织；如果同一患者有多张切片，应预先规定患者级汇总规则，并在适用的区间估计中以患者为重采样单位。记录缺失时，不用文件名相似性替代患者身份确认。病理诊断应描述本研究实际使用的报告、复核和辅助检查流程，不能只引用分类标准。

2 核实外部队列的染色 来源和纳排过程

外部 152 张 MALT 中，111 张带 IHC/特殊染色档案标签，占 73.03%；这不是已经确认的真实染色比例。16 张 SS 的染色同样尚待核实。核实工作应覆盖两个诊断组，尤其关注 8 张 HE 目录材料的来源。若研究目标明确为 H&E 辅助分类，应在真实染色确认后定义相应评估队列，混合材料作为另外的描述性分析。

完整流程应解释 227 张归档材料、223 张成功预测和 168 张最终纳入之间的关系：4 张预测失败、55 张成功预测后未进入最终分析。55/223 为 24.66%。需要记录诊断类别、排除原因、审核人、审核时间以及当时是否接触模型分数。现有 168 张集合不应为了改进结果而改写；如资料核实需要修订集合，应保留原版本、依据和新旧结果对照。对应 C03、C04、C05。

3 将选模表现与独立评估分开

当前内部 AUROC 0.9599 来自参与 checkpoint 选择的 49 张验证切片。正文已明确这一点，因此不需要在每一段再次强调；真正待解决的是患者分组和独立评估，而不是再加几句局限性。固定预测的 bootstrap 区间不能自动纳入选模不确定性。

患者资料核实后，再根据独立患者数和各类病例数决定患者分组的开发方案。可考虑嵌套交叉验证，或有足够样本支持的开发与测试划分；折数不应在患者数未知时先固定。标准化、候选选择、阈值与校准拟合均应限制在对应开发分区。现有外部数据保留为已使用过的外部评估；确认性泛化主张需要从未参与开发决策的新材料。

4 模型增益需要可比对照 并与临床任务价值分开

Hybrid 与 ABMIL 的内部 AUROC 差值为 0.0100，95% 区间为 −0.0184 至 0.0452；外部差值区间也包含零。均值特征 logistic 的外部 AUROC 为 0.8335，归一化均值版本为 0.8462。模型存在可用的排序信号，与“复杂聚合机制优于简单方案”是不同的论点。

后续核心对照可聚焦均值特征 logistic、ABMIL 和 Hybrid，必要时增加一个完整实现且与研究问题相关的 MIL 对照。统一患者分区、编码器、输入协议和合理可比的调参预算；参数量与结构差异仍需报告。已有配置实验先做证据整理，不立即重新铺开大量算法。若保留明确的结构创新主张，再补可隔离因素的均值分支、统计量旁路、区域分组或门控消融。

5 正式读者比较和区域解释需要原始观测

两位病理医生的 49×2 逐例判断、经验、盲法及阅片条件尚未进入可核对材料。即使补齐这些记录，在已参与模型选择的切片上进行比较仍有设计限制。无 AI 的既有汇总记录不能生成有 AI 辅助的效果。建议先核实记录；无法补齐时，将主文读者表图撤下，或仅把已核实的描述性结果放在补充材料。

模型间性能表继续采用加粗和下划线。暂定读者汇总的排名则容易让人误读为优越性证据，建议在核实和设计问题解决前取消该表的排名强调。这是针对比较对象有效性的调整，不影响已核实的模型性能表样式。

Figure 5 的 Case 10 低 margin 窗口应保留为失败案例。已有核查确认裁剪像素和几何关系，但 48.11% 的分割轮廓覆盖不等于真实组织含量。下一步核查背景比例、坐标链和分割质量，并由病理医生在盲法下比较模型选区与对照区域。若需要把区域解释连接到主预测，应使用同一 bag，或明确区分两次输入。门控系数最大不能直接等同于贡献最大。

6 指标展示应回答实际评估问题

当前结果	必须同时提供的背景	对正文的处理
外部准确率 91.07%	全判 MALT 为 90.48%；净多判对 1 张	保留准确率，同时报告平衡准确率和混淆矩阵
外部特异度 68.75%	11/16；每改变 1 张为 6.25 个百分点	报告分子、分母和区间；按患者数规划 SS 补充
外部 NPV 52.38%	11/21，受该队列构成影响	可加入摘要的简短结果句；不作排除诊断主张
外部 AUPRC 0.9733	MALT 比例 90.48%	保留 PR 基准线；现有 Figure 3b 已有，无需新增
排除标签后的敏感度 75.61%	31/41；其余 16 张 SS 染色未确认	保持事后档案标签分析名称，不改称纯 H&E 验证
外部 Brier 0.0919	观察患病比例常数参照约 0.0862	不据 Brier 单独判断校准；参照不能冒充可部署模型

这些指标没有明显的混淆矩阵算术错误；主要问题在样本独立性、队列定义和推断范围。扩充 SS 应按计划的估计精度和独立患者数设计，而不是为了让类别数量看起来平衡。

三 已完成的工作与需要修正的审稿判断

已有结果应补交 不必重复实验

Codex 审稿明确说明只获得正文，没有补充材料、逐切片预测和源码。因此其“补交附件”的要求成立，但不能据此判断本项目没有相应实验。

已有工作	证据位置	仍待解决的部分
9 次受控训练及门控/固定缩放对照	Supplementary Table S15、Figure S4	不等于全部组件已被独立隔离
34 次后续神经训练与 2 个 logistic 对照	S16–S19、Supplementary Results	部分控制重复早期配置，不能把两阶段数量简单相加作为独立重复证据

已有工作	证据位置	仍待解决的部分
20 次额外 bag 推理及分数平均	Figure 6、S10、正文 Results	不等于重复训练；平均后存在敏感度与特异度交换
外部共享参考 bag 的模型比较	Figure 3、S11	仍是完整实现比较，不是只替换聚合层
档案标签剔除与 Brier 参照	S13、S18	不等于染色确认或校准验证
8 个图像窗口的像素、几何和掩膜核查	S12、Supplementary Methods	不等于病理医生对真实组织及病变的注释
19 张补充表、代码与数据压缩包	当前补充 PDF 与 3 个源码/数据归档	尚需机构批准的共享方式、仓库与权重安排

正文可以继续突出内部验证选定的主要 checkpoint，不必恢复 seed 专题章节；补充材料保留完整方法与运行结果，并在给审稿人的材料包中明确索引。当前证据不足以把这个 checkpoint 的最好表现写成训练稳定性或普遍架构优势。

不宜直接照搬的建议

1. **“验证集泄露”需要拆分概念。** 用验证集选 checkpoint 后报告验证指标，是选模复用及乐观偏倚问题；患者是否跨分区则是另一个尚待核实的问题。不能将两者合并为已经证实的泄漏。
2. **“必须三划分或必须嵌套交叉验证”过于绝对。** 应先取得患者数，再选择可行的患者分组评估设计。重新划分已反复查看的数据也不会自动产生一个从未使用过的确认性测试集。
3. **“优势更多来自多统计量汇总而非 gate”尚无充分因果证据。** 豆包提出这一解释，但现有消融不能隔离所有因素。可列为待检验假设，不能写成结论。
4. **“敏感度显著下降”应改为“观察到下降”。** 93.42% 到 75.61% 相差 17.81 个百分点；现有材料未提供支持该表述的显著性检验，且两个集合有重叠。
5. **“多 bag 平均是部署解决方案”需要验证。** 已有平均预测结果，不能只写成未来建议，也不能预设全面改善。外部 20 次平均少一个假阳性，同时多一个假阴性。
6. **“遵循 STARD-AI”不能仅凭文中声明认定完成。** 应提供实际的逐项映射表。代码与数据共享也应按真实可提供的开放或受控途径填写，不推定全部原始数据和权重必须公开下载。
7. **重复的文字提示可合并。** 当前摘要、方法、Table 2 和相关图注已说明验证复用；Figure 1 图注已描述五组向量和统计量旁路，Figure 3b 已有 PR 患病比例基线。可以改善直观性，不必无差别增加警示语。

四 下一步改进计划

阶段 A 整理现有证据和资料需求

现在即可推进。 技术负责人整理正文、补充材料、逐例预测、运行配置和验证报告，建立“审稿意见—证据位置—剩余动作”索引。临床负责人按现有 C02–C06、R01/R02、P01/P03、A03/A04 清单核对医院持有资料。已有匿名临床核对表和读者记录模板可直接复用。

交付物：证据索引、资料交接清单、开发与外部评估时间线初稿。验收条件：每条意见都有负责人和状态；把“尚未交给审稿人”与“尚未完成”分开。该阶段不需要新模型训练。

阶段 B 完成病例级数据审计

阶段 A 后，由医院资料到齐情况决定。 临床负责人确认患者对应、诊断流程、染色与来源、既有纳排记录和伦理条款；数据负责人生成重复/交叉检查、队列流转表和版本差异记录。

交付物：经确认的匿名病例清单、诊断与染色字典、227→223→168 流程及排除原因、更新后的患者级 Table 1。验收条件：纳入分析的病例可追溯；患者交叉为零或已明确处理；未知来源/染色有明确去向；任何集合变化有记录，且不由模型得分决定。

若关键链接或诊断证据无法追回，停止把该集合用于患者独立验证或 H&E 确认性主张，选择继续作为受限的探索性研究，或补充可核实的新队列。单纯删掉 MISSING 标记不能通过这一阶段。

阶段 C 冻结新的评估方案

依赖阶段 B。 临床与统计负责人明确目标病例谱、预期用途及主要指标；算法负责人锁定患者分区、预处理、基线、checkpoint 选择、推理与阈值规则。根据患者数选择可行的交叉验证或留出设计，并说明历史外部数据已使用的范围。

交付物：书面评估协议、患者分区清单、核心基线配置、模型和阈值选择记录。验收条件：用于评估的外层分区不参与预处理拟合、候选选择或阈值/校准拟合；独立确认性队列的资格由使用历史决定，而非文件名决定。

阶段 D 执行必要的评估与病理核查

依赖阶段 C，不以增加模型数量为目标。 优先执行患者级评估和少量可靠基线，补齐类别分母、患者聚类区间及明确的外部分析。算法消融仅服务于仍拟保留的机制主张。ROI 质量核查由算法和病理团队共同完成，保留失败实例。

读者部分先整理已有逐例观测。若目标只是探索性分类研究，完整 AI 辅助阅片试验不是本轮必做的扩展项目；若要主张临床辅助效益，则需要另行设计有无 AI、随机顺序、记忆效应控制及配对结局的研究。概率校准同理：只有保留概率或风险解释目标时才进入核心任务，拟合也须使用独立于最终评估的开发资料。

交付物：患者级预测和指标、核心对照表、ROI 审核记录、适用的读者分析。验收条件：每个数字能追溯到规定输入与选模记录；结论不超出实际完成的设计；保留全部结果，不拼接不同模型/阈值的最优指标。

阶段 E 完成稿件和投稿材料

已能确定的文字修改可提前进行，结果相关改写等待阶段 D。 保留英文论文的临床问题主线，明确探索性定位；核实后更新队列、图表和指标。保留模型性能表的加粗/下划线；读者表图按证据状态处理。Figure 1b 保留，必要时只在 Figure 1a 增加更直观的选模说明。正文不设置 seed 专题，补充材料提供完整实验细节。

交付物：修订稿、逐条审稿处理表、STARD-AI 对照清单、补充材料和可提供的数据/代码访问说明。验收条件：临床、伦理和作者资料缺项有真实内容或明确的范围调整；所有结论有对应证据；图表编号、数值、源码编译及资料链接一致。

工作量安排宜按依赖推进：证据索引和可直接完成的文字整理可先做；数据审计的时间主要取决于医院资料交付；新训练与阅片工作在队列和协议确认后估算。此时不宜承诺固定的投稿日期。

五 本轮优先执行清单

1. 整理已有完整补充材料与分析索引，回应“缺少重复训练/附件”的意见，先避免重复工作。
2. 向临床团队列出患者链接、参考诊断、真实染色与来源、逐项纳排记录四类核心资料需求；沿用已有核对表。
3. 查明并记录外部 4 张预测失败与 55 张未纳入的实际原因和审核流程。
4. 明确读者材料能否补齐逐例观测；据此决定主文保留、移入补充或暂时撤下该比较。
5. 待上述资料确认后，锁定患者级评估方案与少量核心基线，再安排必要实验。

当前最有价值的下一步是完成病例级证据与评估对象的核实。继续美化图表、增加模型数量或重复提示局限，都不能替代这些工作。

六 来源和本地证据索引

- D：豆包，标题“唾液腺 MALT 淋巴瘤与干燥综合征全切片图像二分类研究审稿意见”。本地原文为 sources/reviewer_doubao.md。
- C：Codex 会话“审阅内容”。本地原文为 sources/reviewer_codex.md；其明确声明审阅材料不含补充材料和源码。
- E1：draft_v7_5_revised/MALT_SS_manuscript_v7_5.pdf，18 页。主要定位：队列第 2–3 页，外部结果第 5–7 页，读者第 7–9 页，区域图第 10 页，讨论与方法第 12–15 页。
- E2：draft_v7_5_revised/Supplementary_information_v7_5.pdf，30 页，含 S1–S19、S1–S4 图及 Supplementary Results/Methods。
- E3：draft_v7_5_revised/analysis/review_numeric_audit.json 与 qa/validation_v7_5.json，用于核对既有指标和实验档案。
- E4：draft_v7_5_revised/MISSING_INFORMATION.md 与临床/读者核对表，记录医院资料及作者确认项；文档未复制患者标识。
- E5：draft_v7_5_revised/sections/figures.tex、sections/tables.tex、sections/development_methods.tex、sections/secondary_development_results.tex，用于确认当前呈现与已有分析。

本地来源快照和 source_manifest.json 记录本次读取版本。行动项的负责人角色、依赖、交付物与验收标准另存于《下一步改进行动清单.csv》，便于后续逐项更新。